DOCUMENTATION DE LA BASE DE DONNÉES

UrbanStay Hotels

Base de données PostgreSQL — Brief Data Analyst

Formation Data Analyst — Simplon 2026

1. Présentation générale

UrbanStay Hotels est une chaîne hôtelière fictive présente dans plusieurs villes françaises. Cette base de données a été conçue pour analyser son activité commerciale : réservations, clients, types de chambres et établissements.

Elle est organisée autour de quatre tables :

- `reservations` est la **table de faits principale**. Elle enregistre chaque réservation effectuée.
- `clients`, `chambres` et `hotels` sont des **tables descriptives**. Elles apportent le contexte permettant d'analyser les réservations selon différents axes : lieu, type de chambre, profil client.

2. Architecture du modèle de données

Le modèle est proche d'un modèle dimensionnel, mais il s'agit plus précisément d'un modèle en flocon simplifié.

Dans un modèle en étoile classique, toutes les dimensions sont directement reliées à la table de faits. Ici, ce n'est pas tout à fait le cas :

- `reservations` est la table de faits.
- `clients` est directement reliée à la table de faits.
- `chambres` est directement reliée à la table de faits.
- `hotels` **n'est pas directement reliée à** `reservations`. Elle passe par `chambres`. C'est ce qui caractérise le flocon : une dimension supplémentaire en cascade.

3. Schéma relationnel

```
hotels (hotel_id PK)
    |
    | 1 → N
    |
chambres (chambre_id PK, hotel_id FK)
    |
    | 1 → N
    |
reservations (reservation_id PK, chambre_id FK, client_id FK)
    |
    | N → 1
```

```
    |
clients (client_id PK)
```

Relations

- Un hôtel possède plusieurs chambres (1 → N).
- Une chambre appartient à un seul hôtel (N → 1).
- Une chambre peut être associée à plusieurs réservations au cours du temps (1 → N).
- Une réservation concerne une seule chambre (N → 1).
- Un client peut effectuer plusieurs réservations (1 → N).
- Une réservation appartient à un seul client (N → 1).

4. Dictionnaire de données

Table : hotels

Colonne	Type PostgreSQL	Description métier	Exemple	Clé
`hotel_id`	`SERIAL`	Identifiant unique de l'hôtel	1	`PK`
`nom_hotel`	`VARCHAR(100)`	Nom commercial de l'hôtel	UrbanStay Paris Opéra	
`ville`	`VARCHAR(50)`	Ville où est situé l'hôtel	Paris	
`categorie`	`VARCHAR(20)`	Classement de l'hôtel (3 ou 4 étoiles)	4 étoiles	
`nombre_chambres`	`INTEGER`	Nombre total de chambres de l'hôtel	20	
`date_ouverture`	`DATE`	Date d'ouverture de l'établissement	2018-03-15	

Table : chambres

Colonne	Type PostgreSQL	Description métier	Exemple	Clé
`chambre_id`	`SERIAL`	Identifiant unique de la chambre	1	`PK`
`hotel_id`	`INTEGER`	Référence à l'hôtel auquel appartient la chambre	1	`FK → hotels`
`type_chambre`	`VARCHAR(20)`	Catégorie de la chambre	Confort	
`capacite`	`INTEGER`	Nombre maximum de personnes	2	
`tarif_standard`	`NUMERIC(8,2)`	Tarif de référence par nuit en euros	127.35	

Table : clients

Colonne	Type PostgreSQL	Description métier	Exemple	Clé
client_id	SERIAL	Identifiant unique du client	1	PK
pays	VARCHAR(50)	Pays d'origine du client (peut être NULL)	France	
segment_client	VARCHAR(20)	Segment de clientèle	Loisirs	
date_inscription	DATE	Date de création du compte client	2023-04-12	

Table : reservations

Colonne	Type PostgreSQL	Description métier	Exemple	Clé
reservation_id	SERIAL	Identifiant unique de la réservation	1	PK
client_id	INTEGER	Référence au client ayant effectué la réservation	42	FK → clients
chambre_id	INTEGER	Référence à la chambre réservée	17	FK → chambres
date_reservation	DATE	Date à laquelle la réservation a été effectuée	2024-03-10	
date_arrivee	DATE	Date prévue d'arrivée du client	2024-04-01	
date_depart	DATE	Date prévue de départ du client	2024-04-04	
statut	VARCHAR(20)	État de la réservation	Terminée	
canal_reservation	VARCHAR(30)	Canal par lequel la réservation a été effectuée	Booking	
montant_total	NUMERIC(10,2)	Montant total de la réservation en euros (peut être NULL)	487.50	

> **Valeurs possibles**
> statut : Terminée, Confirmée, Annulée canal_reservation : Site web, Booking, Agence, Téléphone (et variantes à harmoniser) segment_client : Loisirs, Business, Groupe

5. Volumes attendus

Table	Nombre de lignes	Rôle
hotels	8	Dimension — établissements de la chaîne
chambres	160	Dimension — 20 chambres par hôtel
clients	500	Dimension — clientèle enregistrée
reservations	2 000	Table de faits — activité commerciale

Ces volumes peuvent être utilisés pour vérifier que l'import s'est correctement déroulé. Le script de contrôle inclus en fin de

urbanstay_init.sql permet de les vérifier directement dans DBeaver.

6. Période couverte

Les données ont été extraites du script urbanstay_init.sql. Les dates relevées sont les suivantes :

Champ	Date minimale	Date maximale
`date_reservation`	2023-11-06	2025-06-22
`date_arrivee`	2024-01-01	2025-06-23
`date_depart`	2024-01-03	2025-06-30

La période principale d'analyse couvre environ 18 mois, du 1er janvier 2024 au 23 juin 2025.

7. Contenu métier du dataset

Le dataset permet d'analyser l'activité commerciale selon plusieurs axes :

- Géographie : plusieurs villes françaises (Paris, Lyon, Marseille, Bordeaux).
- Établissements : plusieurs hôtels, classés 3 ou 4 étoiles.
- Types de chambres : Standard, Confort, Deluxe, Suite.
- Profil client : plusieurs segments (Loisirs, Business, Groupe) et plusieurs pays d'origine (France, Belgique, Espagne, Allemagne, Italie, Royaume-Uni).
- Canaux de réservation : Site web, Booking, Agence, Téléphone.
- Statuts : Terminée, Confirmée, Annulée.
- Temporalité : données mensuelles permettant l'analyse de tendances et de saisonnalité.
- Données financières : montant total de chaque réservation.
- Durées de séjour : calculables à partir des dates d'arrivée et de départ.

8. Points d'attention sur la qualité des données

Ce dataset n'est pas parfait — et c'est volontaire.

> **Important**
> Certaines données comportent volontairement des incohérences de format, des valeurs manquantes ou des libellés à harmoniser. Leur identification et leur traitement font partie du travail demandé dans Power Query.

Ces imperfections portent sur plusieurs tables et plusieurs types d'anomalies. Elles sont représentatives de situations réelles rencontrées dans des bases de données opérationnelles.

Vous devrez les identifier par vous-même lors de l'exploration des données, puis décider des transformations appropriées dans Power Query avant de construire votre rapport.

9. Exemples de questions d'analyse

La base permet d'étudier notamment :

- Quels hôtels génèrent le plus de chiffre d'affaires ?

- Quelles villes concentrent le plus d'activité ?
- Comment évolue le chiffre d'affaires au fil des mois ?
- Quels canaux de réservation sont les plus utilisés ?
- Les comportements diffèrent-ils selon le segment client ?
- Quels types de chambres génèrent le plus d'activité ?
- Quelle est la durée moyenne des séjours ?
- Quel est le taux d'annulation ? Varie-t-il selon les hôtels ou les canaux ?
- Observe-t-on des périodes plus ou moins actives dans l'année ?
- Est-il possible d'estimer un taux d'occupation par chambre ?

10. Utilisation dans Power BI

Une fois la base créée dans PostgreSQL, vous la connecterez à Power BI Desktop afin de :

- explorer et préparer les données dans Power Query ;
- construire le modèle relationnel entre les tables ;
- créer les indicateurs nécessaires à l'analyse ;
- produire des analyses visuelles interactives ;
- assembler un tableau de bord à destination de la direction.

> **À noter**
> La connexion à PostgreSQL depuis Power BI nécessite le connecteur PostgreSQL. Si ce connecteur n'est pas installé sur votre poste, votre formateur vous indiquera la procédure à suivre.

Ce que vous devez retenir

1. reservations est la table de faits : elle contient les événements commerciaux à analyser (une ligne = une réservation).
2. clients, chambres et hotels sont des tables descriptives : elles enrichissent les réservations avec des informations contextuelles.
3. Le modèle est en flocon simplifié : hotels n'est pas directement reliée à reservations — la jointure passe par chambres.
4. Les deux principaux chemins d'analyse sont : reservations → chambres → hotels et reservations → clients.
5. Ce modèle est exploitable directement dans Power BI en définissant les relations entre tables dans la vue Modèle.
6. Les données comportent des imperfections volontaires à traiter dans Power Query avant toute analyse.